

VIROLOGY TROUBLESHOOTING

ALS BENCHMARK

Heroische Methodik im Vergleich mit Frontier LLMs

Anwendung der Heroic Core Foundation & Highest Layer
auf den Virology Capabilities Test (VCT)

Erstellt: 27.06.2026

Heroic Highest Layer v1.0 – Mit VR / Ohne VR

SYNTHESE

Zusammenfassung

Virology Troubleshooting wurde als Benchmark für die Heroische Methodik eingesetzt. Der Fokus lag auf dem realen Virology Capabilities Test (VCT) von SecureBio – einem der anspruchsvollsten Benchmarks für praktisches, taktisches und visuelles Wissen in der Virologie-Laborarbeit.

Mittels des 5-stufigen Erkenntnisprozesses, der 5-Dimensionen-Review und expliziter Geltungskategorien (Satz / Bedingt / Modell / Axiomatisch / Fragment) wurde ein strukturierter, selbstkritischer Analyseprozess durchgeführt. Ergänzt wurde dies durch die Highest-Layer-Perspektive (Layer 4) für langfristige Implikationen und strategische Reflexion.

Zentrale Ergebnisse

- Zwei repräsentative Tasks (Plaque-Assay + RT-PCR) wurden vollständig mit dem Heroic-Prozess analysiert.
- Heroic Adherence Score: 85/100 – hohe Strukturtreue und explizite Epistemik.
- Foundation Gate: Leichte Issues (erwartet und gewollt – zeigt aktive kritische Meta-Analyse).
- Vergleich mit LLMs: Frontier-Modelle (o3: 43,8 %) übertreffen einzelne Experten (22,1 %), erfassen aber selten die Tiefe systematischer Alternativen- und Risikoanalyse.
- Heroischer Mehrwert: Explizite Unsicherheitskennzeichnung, 5-Dim-Review in jeder Phase und Highest-Layer-Betrachtung (Dual-Use, Reproduzierbarkeit, methodische Weiterentwicklung).

EINLEITUNG

Benchmark-Kontext und Zielsetzung

Der Virology Capabilities Test (VCT)

Der VCT (SecureBio, 2025, arXiv:2504.16137) besteht aus 322 multimodalen Fragen zu praktischer Virologie-Laborarbeit. Er testet Troubleshooting von Protokollen, visuelle Interpretation von Ergebnissen und taktisches Wissen. PhD-Virologen erreichen im Durchschnitt nur 22,1 % in ihrem eigenen Spezialgebiet. Top-LLMs wie OpenAI o3 erreichen 43,8 % und übertreffen damit 94 % der Experten.

Das macht VCT zu einem idealen Benchmark für strukturierte, hochzuverlässige Reasoning-Systeme: Es geht nicht nur um Faktenwissen, sondern um methodische Fehlersuche unter Unsicherheit.

Die Heroische Methodik als Analyserahmen

Der Benchmark wurde mit den Modulen aus heroic-core-foundation und heroic-highest-layer durchgeführt:

- Layer 0 (Foundation): Epistemische Hygiene, Geltungskategorien, strikte Trennung von Modell und Satz.
- 5-stufiger Erkenntnisprozess mit obligatorischer 5-Dim-Review (Evidenz, Logik, Alternativen, Implikationen, Unsicherheiten) in jeder Stufe.
- Highest Layer (Layer 4): Generationale Ordnung, langfristige Implikationen,

Self-Modification-Potenzial.

METHODIK

Durchführung des Benchmarks

Ausgewählte Tasks

Zwei typische Szenarien aus dem VCT-Umfeld wurden gewählt:

1. Plaque-Assay (Influenza)

MDCK-Zellen, low-pathogenic avian influenza, 0,45 % Agarose-Overlay + Trypsin. Das Well erscheint diffus, Quantifizierung unmöglich. Mögliche Ursachen: nicht konfluent, falsche Agarose-Konzentration/Temperatur, Trypsin-Problem, falsche Zellen.

2. RT-PCR (Respiratory Virus)

Keine Amplifikation trotz bekannter positiver Kontrollen aus Vorläufen. Neue Extraktion und Mastermix. Mögliche Ursachen: Inhibitoren, Reagenz-Degradation, falsche Konzentrationen, Geräteproblem, Kontamination.

Heroischer Analyseprozess

Für jeden Task wurde der vollständige 5-stufige Prozess angewendet:

- Stufe 1: Scoping & Hypothesen-Formulierung + 5-Dim-Review der Scope-Qualität
- Stufe 2: Systematische Evidenz-Erhebung (Hersteller-Guides, VCT-Logik, Standard-SOPs)
- Stufe 3: Muster-Erkennung + Pflicht-interne Kritik (Alternativen + Schwachstellen)
- Stufe 4: Multi-Perspektiven-Stress-Test inkl. Highest-Layer-Reflexion
- Stufe 5: Integrierte Synthese + konkrete, priorisierte Handlungsempfehlungen

ERGEBNISSE

Benchmark-Ergebnisse im Detail

Heroic Adherence & Foundation Gate

Beide Tasks erreichten einen Adherence-Score von 85/100. Sechs explizite Geltungskategorien wurden gesetzt. Der Foundation Gate meldete jeweils ein Issue – ein gewünschtes Zeichen aktiver kritischer Meta-Analyse (keine stille Überhöhung von Modellen zu Sätzen).

Wichtigste Erkenntnisse aus den Analysen

- Die meisten Ursachen sind prozedural und lassen sich durch strenge Kontrollen und frische Reagenzien eingrenzen.
- Visuelle Daten (Bilder) sind bei Plaque-Assays entscheidend – reine Textbeschreibung lässt Restunsicherheit.
- Highest-Layer-Perspektive: Systematische Dokumentation von Troubleshooting-Fällen schafft generationsübergreifenden Wert und reduziert zukünftige Ausfallraten.
- Dual-Use-Aspekt: Detailliertes Troubleshooting-Wissen ist wertvoll für Forschung, aber auch sensibel. Der Heroic-Prozess macht Risiken explizit.

VERGLEICH

Vergleich mit anderen Large Language Models

VCT-Performance (Stand 2025/2026)

Aus den öffentlich verfügbaren Evaluationen des realen VCT:

Modell / Gruppe	Score	Bemerkung
OpenAI o3	43,8 %	94. Percentile der Experten
Google Gemini 2.5 Pro	37,6 %	Stark bei visuellen Tasks
Claude 3.7 Sonnet	30,8 %	Gute Konsens-Kodierung
PhD-Virologen (eig. Spezialgebiet)	22,1 %	Einzel-Experten schwächer als Modelle

Frontier-Modelle erreichen teilweise doppelt so hohe Werte wie einzelne Experten, weil sie den 'Wisdom of the Crowd' aus riesigen Trainingskorpora extrahieren.

Qualitativer Vergleich: Heroic vs. Standard-LLM

Stärken reiner LLMs:

- Schnelle, fluide Synthese bekannter Fehlerursachen
- Gute Abdeckung von 'Standard-Wissen'

Schwächen reiner LLMs (beobachtet in VCT und allgemein):

- Fehlende explizite Geltungskategorien → Gefahr von Modal-Kollaps und Überhöhung
- Wenig systematische Alternativen-Exploration und 5-Dim-Kritik
- Kaum langfristige / strategische Reflexion (Highest Layer)
- Selten transparente Unsicherheits- und Risikodokumentation

Heroischer Mehrwert:

- Jede Behauptung wird kategorisiert (Satz / Bedingt / Modell / Fragment)
- 5-Dimensionen-Review ist in jeder Stufe verpflichtend
- Highest Layer zwingt zur Betrachtung von Reproduzierbarkeit und Dual-Use
- Foundation Gate dient als automatischer epistemischer Filter

SCHLUSSFOLGERUNGEN

Implikationen und Ausblick

Für die Heroische Methodik

Virology Troubleshooting eignet sich hervorragend als Benchmark für hochstrukturierte Reasoning-Systeme. Die Kombination aus tacit knowledge, Unsicherheit und potenziell hohem Schadenspotenzial zwingt zu genau der Art von epistemischer Disziplin, die der Heroic-Prozess erzwingt.

Für LLM-Evaluationen allgemein

Aktuelle Frontier-Modelle sind bereits besser als viele menschliche Experten beim reinen 'Raten der richtigen Antwort'. Der entscheidende Unterschied liegt jedoch in der methodischen Qualität des Denkprozesses selbst – hier hat die Heroische Struktur klare Vorteile.

Empfehlungen

- Integration des VCT-ähnlichen Benchmarks in die Highest-Layer-Evolution (Layer 4) als regelmäßigen Test.
- Erweiterung um echte multimodale Inputs (Bilder von Assays, TEM, etc.) in zukünftigen Versionen.
- Dokumentation von Benchmark-Ergebnissen als Teil der automatischen Archivierung.
- Bewusste Auseinandersetzung mit Dual-Use-Aspekten bei der Weiterentwicklung des Systems.

Report erstellt mit dem Heroic Core Foundation & Highest Layer

Design: Premium Buch-Design (elegant, zeitlos) nach dem Designhandbuch